


뉴스·소셜 토픽 추출 및 입법예고 연계를 통한 입법수요지수 산출 모델

◆ 조윤빈, 최성현

Shall we Data?



Data Science Team
Incheon National University



Data Science Team
Incheon National University

Contents

- ◆ 진행 배경
- ◆ 프로젝트 설명
- ◆ 진행 절차 및 데이터셋
- ◆ 결과 및 해석
- ◆ 결론

◆ 진행 배경 (1/2)

■ 여론 데이터의 증가와 반영의 어려움

- 뉴스와 SNS에서 법률 관련 여론이 실시간으로 대량 생산되지만, 여론 데이터들의 포맷이 다르고 흩어져 있어 곧바로 입법 절차에 연결되기 어려움
- 여론이 퍼지는 속도와 제도 절차(검토·예고·심사)의 속도가 달라, 각 정책 기간에 맞춘 정확한 신호 포착이 필요함


■ 실시간 비정형 텍스트의 정량 연결 부족

- 대규모 비정형 텍스트의 실시간성을 정책결정 프로세스에 정량적으로 연결하는 표준화된 방법론·인프라가 부족함
- 중복·잡음·조작(Fake/여론 부풀리기) 리스크를 체계적으로 제어하고, 그 과정에서 우선순위를 산출하는 데이터 거버넌스가 필요함

◆ 진행 배경 (2/2)

■ 여론 데이터를 구체적인 입법예고 단위로 분류하거나 연계하는 연구는 부재함

- 현준원 외(2023)이 진행한 연구에서는 여론 데이터를 몇 가지 기존 법률 유형으로 분류하는데 그쳤음
- 입법예고는 입법절차에서 국민의 여론이 공식적으로 반영되는 핵심 단계로 예고 기간은 최소 20일임
 - 입법예고 : 특정 정책과 관련된 의견을 법제화하기 전에 취지와 주요내용을 사전 공개하고 의견 수렴하는 과정.



자료: 입법과정 전체

■ 입법예고가 진행되기까지 여론과 관련하여 중요하게 작용하는 요인을 체계적으로 확인했던 바가 없음

- 입법과 여론 간의 관련성을 다룬 연구는 존재하지만 이를 계량적으로 검증한 선행연구도 부족 (Hakimi, 2006)
- 관련성을 나타낼 수 있는 지표 예시 : 여론 매체 존재 여부, 빈도, 긍정·부정 방향성

◆ 프로젝트 설명

■ 프로젝트 목적


뉴스·SNS 등 실시간 여론 데이터를 일정 기간 내 입법예고와 매칭하여 사회적 수요를 정량적으로 파악하고,
이를 입법수요지수(LDI)로 제시해 조기 입법 판단에 활용할 수 있는 체계를 구축하는 것

■ 프로젝트 목표

- 여론 데이터를 토픽 모델링하여 도출된 결과들과 입법예고 간 의미(Semantic Embedding) + 시간(Temporal Window)을 기반으로 매칭하는 과정을 설계하고 법의 종류에 따른 결과 차이를 확인
- 토픽 모델링의 결과들이 가지는 속성들을 통합하여 입법수요지수(Legislative Demand Index, LDI)를 정의하고 도출
 - 여론이 가지는 특징에 따라 5개의 기준으로 관련 파생변수들을 생성하고 이를 통합하여 단일 점수를 설계
- 프로젝트의 일련 과정(여론 데이터 업로드→분석→지표 산출→시각화)을 웹으로 구현하여 결과를 확인하고 공유

◆ 진행 절차 및 데이터셋

■ 진행 절차



■ 데이터셋 구축

- 4개 상위법으로 분류된 약 26만 건 뉴스·소셜/입법예고 데이터
 - 상위법 : 개인정보보호법(개인정보), 정보통신망법(정보통신), 자본시장법(자본시장), 아동복지법(아동복지)
 - 뉴스·소셜 출처 : 한국언론진흥재단 빅카인즈 언론데이터, X(구 Twitter), 온라인 커뮤니티, Naver blog, Instagram, Youtube
 - 기간: 2025년 1월 ~ 2025년 8월 시간대별 데이터
- 구성 필드: 분류 법, 기사 제목, 본문내용, 입법예고번호, 법안명, 제안자구분, 소관위원회, 주요내용, 의견수

◆ Step1. 데이터 전처리

■ 텍스트 데이터 전처리 파이프라인

1. 뉴스·소셜 원문에 대해 노이즈 정리(전화번호·URL·반복어·공백)
2. 문자 표준화(이모티콘/특수문자 변환·한자→한글+불용어 처리), 형태소 추출(KoNLPy)
3. 광고/홍보 필터링(키워드 교집합 규칙)
4. 시간·형식 표준화, URL 기반 사이트 출처 분류
5. 자카드 척도로 유사도 판단 후 임계값(0.9) 이상 중복 데이터로 판단
6. 뉴스/소셜에 따라 흔하게 등장하는 불용어 추가 후 제거

content	processed_content	processed_content_str
올해 1분기 산업현장에서 사고로 숨진 노동자는 137명(잠정)에 달한다.[올해, '분기', '산업', '현장', '사고', '숨지다', '노동자', '잠정', '특히', '업종별로', '건설업', '사망자는', '71명으로', '전년', '동기보다', '10.9%', '증가했다', '특히', '업종', '별로', '건설업', '사망자', '동기', '증가', '업', '사망자', '동기', '증가', '하다']...	올해 1분기 산업현장에서 사고로 숨진 노동자는 137명(잠정)에 달한다. 특히 업종별로 건설업 사망자는 71명으로 전년 동기보다 10.9% 증가했다. 특히 업종 별로 건설업 사망자 동기 증가 하다...	올해 1분기 산업 현장 사고 숨지다 노동자 잠정 특히 업종 별로 건설업 사망자 동기 증가 하다...
오늘(13일) 아침 9시 39분쯤, 경북 안동시 풍산읍 노리 중앙고속도로 서안동 나들목 인근에서 벌목 작업을 하던 30대 작업자 A씨가 나무에 깔렸습다. 경북소방본부 등에 따르면, ...	오늘(13일) 아침 9시 39분쯤, 경북 안동시 풍산읍 노리 중앙고속도로 서안동 나들목 인근에서 벌목 작업을 하던 30대 작업자 A씨가 나무에 깔렸습다. 경북소방본부 등에 따르면, ...	오늘 아침 경북 안동시 풍산읍 노리 중앙 고속도로 안동 나들목 인근 벌목 작업 하다 대다 작업 나무 깔리다 경북 소방본부 따르다...
고용노동부 중대재해처벌법 위반 여부 조사 한국도로공사 하청업체 소속 30대 근로자가 벌목 ...	고용노동부 중대재해처벌법 위반 여부 조사 한국도로공사 하청업체 소속 30대 근로자가 벌목 ...	고용노동부 중대 재해 처벌 위반 여부 조사 한국 도로공사 하청 업체 소속 대다 근로자 벌목 ...

자료. 텍스트 전처리 전 후 결과 예시 3행

◆ Step2. 뉴스기반 토픽 도출 및 입법예고 매칭

■ 뉴스기반 토픽 도출 과정

1. 법안 별 입법KR-SBERT 임베딩과 UMAP 차원축소 후 BERTopic으로 토픽 정규화
 - SentenceTransformer를 사용하여 법안 별 토픽 모델링에 영향을 미치는 주요 파라미터 (min_topic_size, n_neighbors, n_components)의 최적값 도출
 - $C_v(\text{coherence_score}) > 0.8$ 달성으로 토픽 일관성 확보 시드 고정으로 재현성 확보
2. BERTopic 사용하여 토픽모델링 진행

■ 입법예고 매칭 과정

1. 입법예고의 목록을 불러온 후 토픽과 코사인 유사도로 매칭(임계값: 0.6)
2. 입법예고 법안 별 예고기간을 고려한 시계열 라벨링 후 유사도 매칭(임계값: 0.6)
 - 법안 발의 날 기준(start time)

◆ Step3. 토픽-소셜 매칭 및 파생 변수 생성

■ 토픽-소셜 매칭 과정

1. TF-IDF 학습을 통해 빈도수가 너무 적거나 많은 토큰 제거
 - 전처리 진행한 소셜 데이터, 해당 법안 토픽 ID 및 토픽 text 사용
 - min_df=5, max_df=0.8 설정
2. 코사인 유사도를 기준으로 매칭 후 적정 임계값 판단(0.1)
3. 추출한 데이터는 임계값 적용하여 매칭한 데이터 필터링(유사도 0.1 이하로 매칭된 데이터 제거)

■ 파생 변수 생성

- 토픽 ID 별로 생성될 수 있는 특징들을 5개의 축(화제성/중심성/응집성/확산성/지속성)으로 나누어 집계
- Step.2에서 BERTopic으로 도출한 topic_id에 대하여 의미·시간(180일) 규칙을 통과한 토픽에 대해 수치를 계산
- 생성한 변수들의 상관관계 및 입법수요지수(LDI) 도출시 활용 가능성 확인

◆ Step4. 입법수요지수(LDI) 산출

▪ 파생변수 측 정의 및 대표 피처 선정


- **Buzz (화제성, 양·활동성):** total_posts, max_zscore, ewma_slope, sent_ratio, sent_per_100w, punc_q.
- **Focus (중심성, 주제 집중·구조):** entropy, rep_kw_count, rep_kw_total, uniq_words.
- **Depth (응집성, 정보 밀도):** avg_tok_len, avg_len, sent_ratio, sent_per_100w.
- **Spread (확산성, 확산·다양성):** source_entropy_norm, ewma_slope, speed_intensity.
- **Penalty (지속성 페널티):** days_to_peak(길수록 -).

▪ 구조와 산식 $LDI = 0.30 \cdot B + 0.25 \cdot F + 0.25 \cdot D + 0.20 \cdot S - 0.15 \cdot P$


- Step3. 파생변수 결측 일관 처리 및 z-score 표준화 수행
- 가중치는 **상관·집단 비교, 효과크기, FDR 보정** 결과를 근거로 설정하고 보완함
 - 상관 분석은 Shapiro 기반 정규성 진단 후 Welch t 또는 Mann-Whitney U 적용

◆ Step5. 시각화·대시보드 구현

- Flask 서버·분석 모듈·UI 템플릿의 3계층 아키텍처 채택
 - 입력은 법안 종류 단위 파일 업로드 분석 실행 후 결과 직렬화
 - 출력은 생성 요약과 상위 키워드 목록 키워드 네트워크 HTML 제공
- 카드형 UI에 토픽 모델링 결과 AI 요약과 키워드 네트워크 메타 동시 제시



자료. 시각화 구현 예시



◆ 결과 및 해석

■ 데이터 분포 요약

- 표본: 297개 토픽(연계 lawmake=1: 44개(14.8%), 비연계 253개)
- 중요도(LDI): 평균 0.368, 중앙값 0.357, 상위10% 0.554, 최대 1.000, 지니 0.224(상위 꼬리 제한적)
- 법별 평균(높은 순): 개인정보 0.423 > 정보통신 0.401 > 아동복지 0.347 > 자본시장 0.316
- 법별 연계율(높은 순): 자본시장 20.5% > 개인정보 16.3% > 아동복지 13.9% > 정보통신 6.3%
- 주의: 이번 결과는 뉴스 텍스트 피쳐 중심(일부 소셜 확산 피쳐 결측)

■ 집단 차이(연계 1 vs 비연계 0, FDR<0.05)

- 연계 토픽은 더 길고(문자·단어), 어휘 다양성↑, 반복↑, 긍정 비중↑.
 - 예) avg_tok_len 2.956 vs 2.878, sent_ratio 0.536 vs 0.420.
- 느낌표 사용↓. 예) punc_exc 2.09 vs 2.98.

◆ 결과 및 해석

■ 상관관계 확인 후 핵심 피처

- 감성 비율(sent_ratio): Spearman 0.877, Pearson 0.843 → 가장 강한 1순위 신호.
- 100단어당 감성 강도(sent_per_100w): 0.858 / 0.822 → 감정의 "세기"도 핵심.
- 어휘·길이 계열:
 - 평균 토큰 길이(avg_tok_len) **0.609 / 0.579**,
 - 고유어 수(uniq_words) **0.601 / 0.536**,
 - 어휘 다양성(entropy) **0.615 / 0.572**,
 - 단어/문자 길이(word_len/char_len) **유의한 양의 관계 +**.
- 반복 키워드 규모: rep_kw_count 0.548 / 0.508, rep_kw_total 0.340 / 0.420 → 핵심어 반복이 높을수록 중요도 ↑.
- 보조 신호: 물음표(punc_q) 0.318 / 0.356(보조적 +), 느낌표(punc_exc)는 전체 상관 미약.

◆ 결과 및 해석

■ 법별 주요 신호(상관 상위)

- 자본시장: 감성 지표 강함(ρ sent_per_100w 0.842, ρ sent_ratio 0.812), 선형에선 어휘/반복도 큼(r uniq_words 0.765, r rep_kw_count 0.737).
- 아동복지: 감성 강함(ρ 0.751/0.739), 선형에선 어휘/반복이 강함(r 0.813/0.793).
- 개인정보: 감성 중심 패턴은 유지(ρ 0.728/0.724)하나 절대 상관은 다소 낮음.
- 정보통신: 감성 비율·강도 최강(ρ 0.854/0.846).

■ 민감/둔감 법안 분류 LDI 가중 조정 원칙

- 민감(예측 용이): 자본시장, 아동복지 — 텍스트 길이·반복·어휘·감성에 잘 반응
 - 민감군(자본시장·아동): sent_ratio, sent_per_100w, word_len/char_len, uniq_words, entropy, rep_kw_total 가중 ↑.
- 둔감(예측 어려움): 개인정보, 정보통신 — 텍스트 지표만으로는 반응 약함(보정 필요)
 - 둔감군(개인정보·정통): 위 가중은 보수 적용, 대신 소셜 확산·출처 다양성(spread/source_entropy) 가중 ↑

■ 기여사항

- 여론 텍스트에서 입법예고를 의미·시간 축으로 연결하는 데이터 파이프라인을 구현함
- 토픽 관련 파생 변수들을 통합하여 다기준 입법수요지수(LDI)를 제안하고 핵심 텍스트 지표와의 양(+) 관계를 검증함
- Flask 웹·대시보드 기반 의사결정 지원 시스템을 구현하고 운영 가능성을 확인함
- 법별 예측 가능성 차이를 규명하고 자원 배분을 위한 '민감 우선-둔감 보정' 운영 프레임을 제시함

■ 한계점, 개선방안

- 둔감군은 텍스트만으로 부족해 거시 변수·소셜 확산 지표를 보강하지 않으면 예측력이 제한되며 이를 검증할 수 있는 지표가 부재함
- 표본·라벨 불균형과 180일·유사도 임계 의존으로 지연·누락·과포착 위험이 존재함
- 플랫폼 편향·전처리 손실·사전 미스매치·분석 범위 한계로 결과의 일반화가 제약되며, 결과는 인과가 아닌 관측 상관·예측 가능성임
- 임계값·가중치 주관성을 줄이기 위해 외부 벤치마크와 사전등록 규칙, 베이지안 튜닝 등의 객관화 절차가 필요함.



Q&A
감사합니다